

Аналитический отчет по анализу данных недвижимости

Автор: [Пальчак Тимофей Станиславович]

Группа: [ИСП-23В]

1. Введение

1.1 Цель исследования

Целью данной работы является анализ данных о недвижимости, полученных с [помощью API DomClick](#), для выявления факторов, влияющих на стоимость квадратного метра жилья, и подготовки данных для дальнейшего использования в построении моделей машинного обучения.

1.2 Задачи:

1. Получить и очистить данные о недвижимости.
 2. Провести анализ числовых и категориальных переменных.
 3. Заполнить пропущенные данные и подготовить датасет для визуализации и корреляционного анализа.
 4. Построить визуализации для выявления ключевых закономерностей.
 5. Сформировать выводы и рекомендации для использования данных в дальнейшем.
-

2. Методология и инструменты

Для выполнения поставленных задач использовались следующие инструменты и библиотеки:

- **Python** для обработки данных и автоматизации запросов.
- **Библиотеки pandas, numpy** для анализа и подготовки данных.
- **Визуализационные библиотеки:** seaborn и matplotlib для построения графиков и тепловой карты корреляции.
- **KNN Imputer** для заполнения пропущенных значений на основе значений ближайших соседей.

Источником данных является [API DomClick](#). Используются запросы к API для получения информации о квартирах в Москве по различным параметрам (количество комнат, площадь, этаж и т.д.).

3. Этапы работы

3.1 Загрузка данных через API DomClick

Для загрузки данных был разработан класс DomClickApi, который выполняет автоматизированные запросы к [API DomClick](#) с необходимыми параметрами (тип недвижимости, регион, количество комнат и т.д.). На каждом этапе выводились промежуточные данные для проверки корректности полученной информации.

3.2 Предварительная обработка данных

После загрузки данных из API был выполнен следующий процесс:

- Создан DataFrame с нужными колонками: price, area, rooms, square_price, subways, monthly_payment.
- Обнаружены пропущенные значения в колонке subways и monthly_payment, которые были обработаны с использованием [KNN Imputer](#) и других методов.

3.3 Выявление столбцов с пропущенными значениями

Проверка на пропущенные значения была выполнена с помощью кода:

В результате были обнаружены пропуски в колонках subways, monthly_payment и других, которые были заполнены с помощью [KNN Imputer](#) и других методов.

3.4 Визуализация данных

Для анализа взаимосвязи между ценой за квадратный метр и другими признаками были построены следующие графики:

- **Диаграммы рассеяния** для колонок price, area, rooms относительно square_price.
- **Тепловая карта корреляции**, показывающая степень взаимосвязи между числовыми переменными (см. приложенный график).

4. Результаты и выводы

4.1 Анализ корреляции

Тепловая карта корреляции показала следующие ключевые зависимости:

- **Цена за квадратный метр (square_price)** наиболее сильно коррелирует с общей ценой (price) и площадью квартиры (area).
- Количество комнат (rooms) показало слабую корреляцию с ценой за квадратный метр, что говорит о меньшем влиянии этого параметра на стоимость в сравнении с общей площадью и общей ценой.

4.2 Обработка пропущенных значений

Использование [KNN Imputer](#) позволило корректно заполнить пропуски в колонке subways, основываясь на схожих значениях соседних объектов. Данный метод обеспечил более точное восстановление данных по сравнению с простыми статистическими методами (среднее, медиана и т.д.).

5. Рекомендации

1. Использование обработанных данных для построения модели ценообразования:

- Данные готовы для обучения модели машинного обучения, которая может предсказывать стоимость квартиры на основе признаков price, area, rooms, subways.

2. Регулярное обновление данных через API:

- Для актуальности модели рекомендуется периодически обновлять данные через [API DomClick](#), чтобы учесть изменения на рынке недвижимости.

3. Дальнейший анализ категориальных переменных:

- Рекомендуется детально изучить влияние других категориальных признаков, таких как renovation и placement_type, которые могут оказать влияние на цену.
-

6. Заключение

В ходе работы был проведен анализ и очистка данных о рынке недвижимости, полученных из [DomClick API](#). Выполненная обработка позволила выявить ключевые зависимости между параметрами объектов и подготовить данные для дальнейшего использования в построении моделей предсказания цен. Данные готовы к применению для задач машинного обучения и мониторинга изменений рынка.

Приложения

1. Примеры кода для работы с API и очистки данных.
 2. Графики зависимости и корреляции.
-

Отчет составлен на основе данных, полученных из [DomClick API](#).